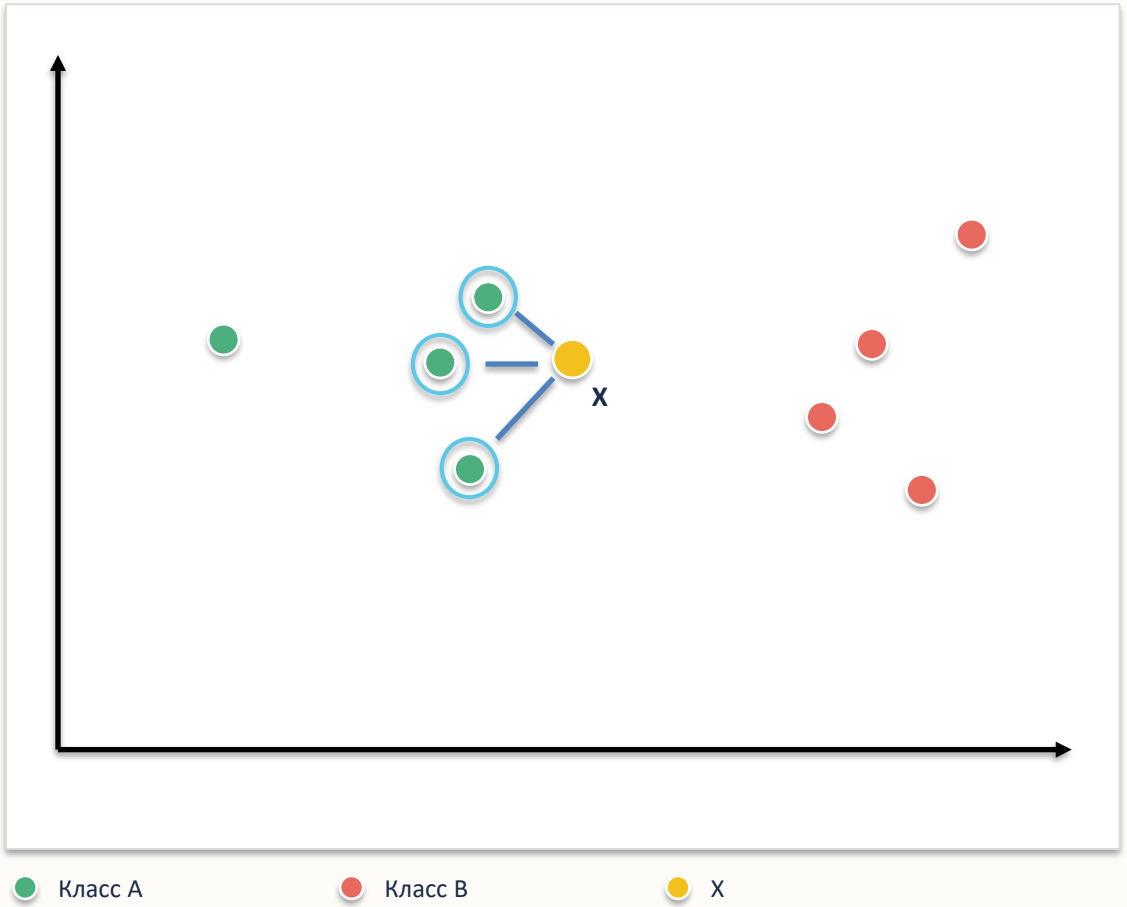
Метод k ближайших соседей

k-Nearest Neighbors (k-NN)

Основы машинного обучения

Работу выполнили:

Дмитриенко Яна, Шабанова Арина



Что делает k-NN

Новый объект получает ответ по похожим примерам

Идея

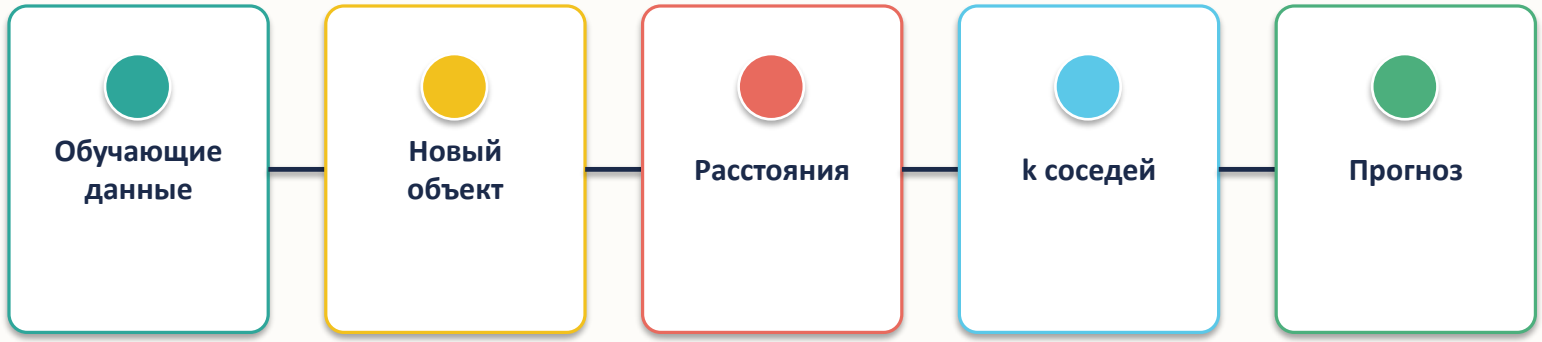
Найти объекты обучающей выборки, которые ближе всего к новому объекту.

Классификация

Выбираем класс, который чаще всего встречается среди k соседей.

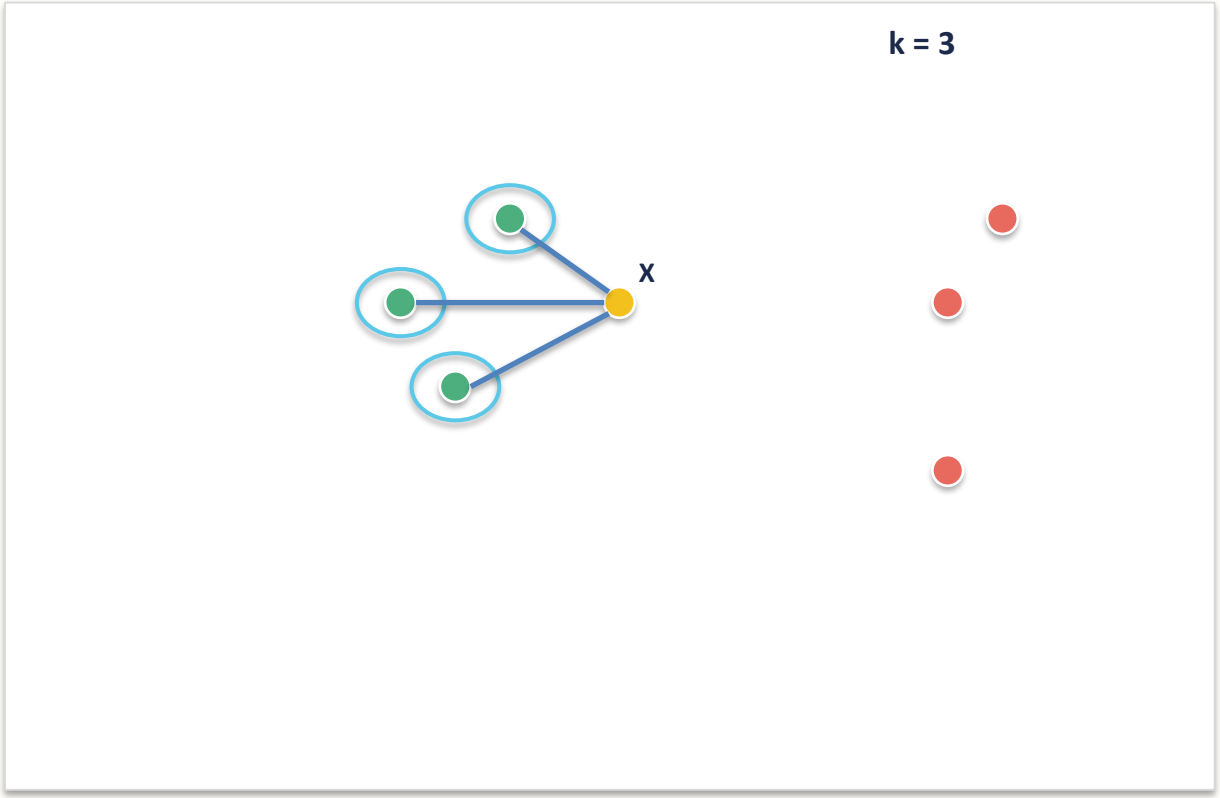
Регрессия

Берём среднее или взвешенное среднее значений ближайших соседей.



Интуиция: ответ от соседей

Если рядом большинство объектов класса A, прогноз тоже будет A



3 ближайших соседа → класс A

1. Считаем расстояния

Для нового объекта X вычисляем близость ко всем объектам обучающей выборки.

2. Берём k соседей

Например, k = 3: выбираем три ближайших объекта.

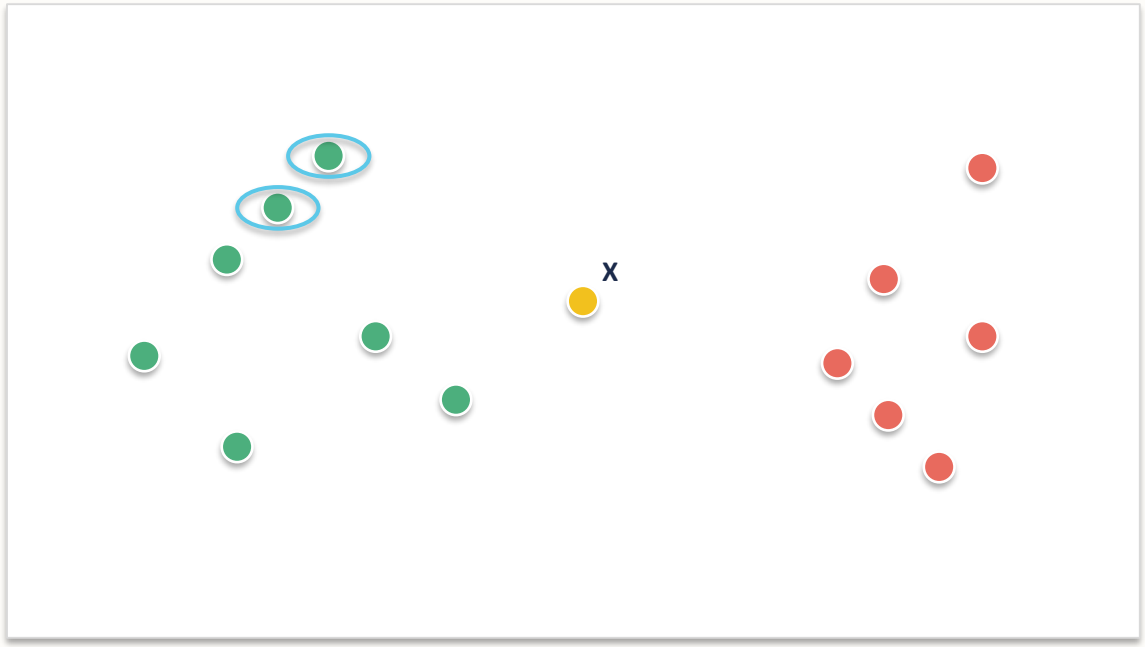
3. Голосуем

Большинство соседей класса A → новый объект относим к A.

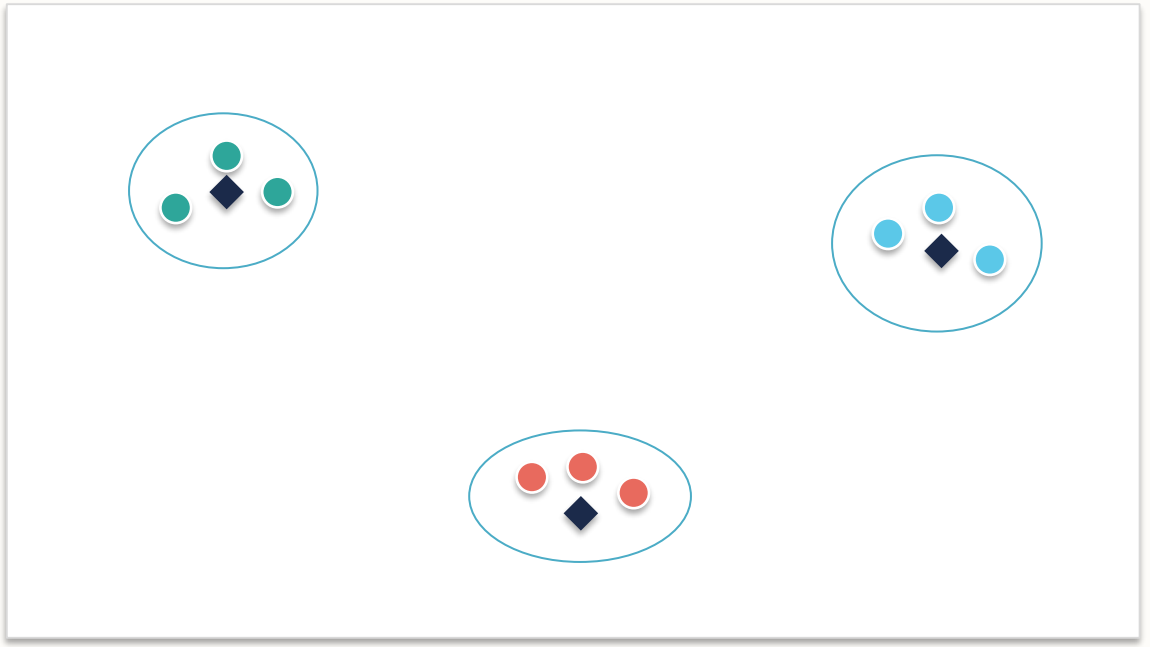
k-NN и k-means: не путать

Похожие названия, но разные задачи

k-NN



k-means



k-NN

Обучение с учителем: есть метки классов и новый объект.

k-means

Обучение без учителя: заранее нет правильных классов.

Главное

В k-NN k — число соседей, в k-means k — число кластеров.

Алгоритм k-NN

Пять шагов работы метода

1. **Новый объект**
2. **Посчитать расстояния**
3. **Отсортировать**
4. **Выбрать k ближайших**
5. **Сделать прогноз**

Для классификации — голосование, для регрессии — усреднение.

k-NN: локальный поиск вместо итерационного обучения

У k-NN нет итерационного обучения как в k-means или бустинге

Нет глобальной функции потерь

На этапе fit алгоритм в основном запоминает обучающие данные.

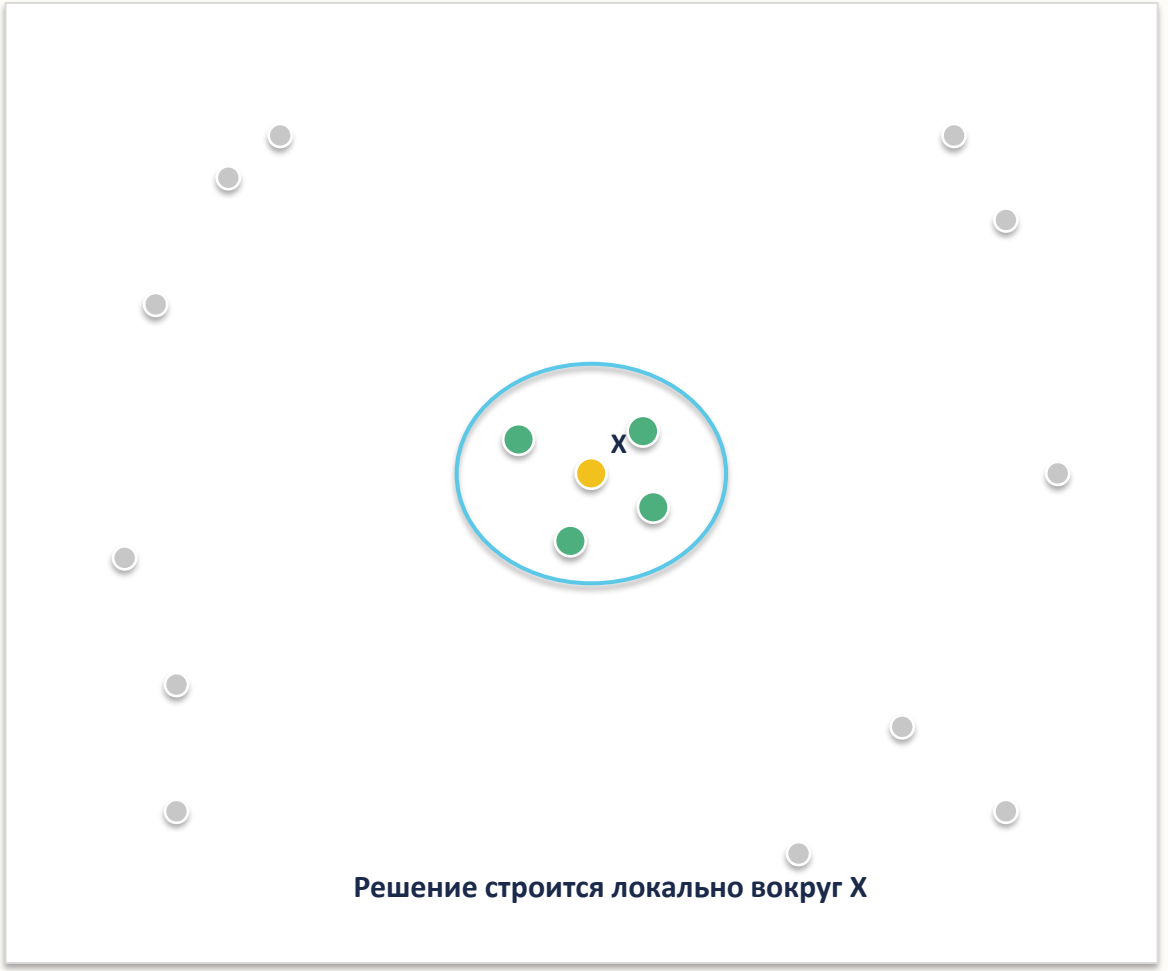
Минимум расстояний

При predict мы выбираем объекты с наименьшими расстояниями до X.

Локальное решение

Решение зависит от окрестности нового объекта, а не от одной общей модели.

$N_k(x)$ = k объектов с минимальным $d(x, x_i)$



Евклидово расстояние

Как измеряется близость объектов

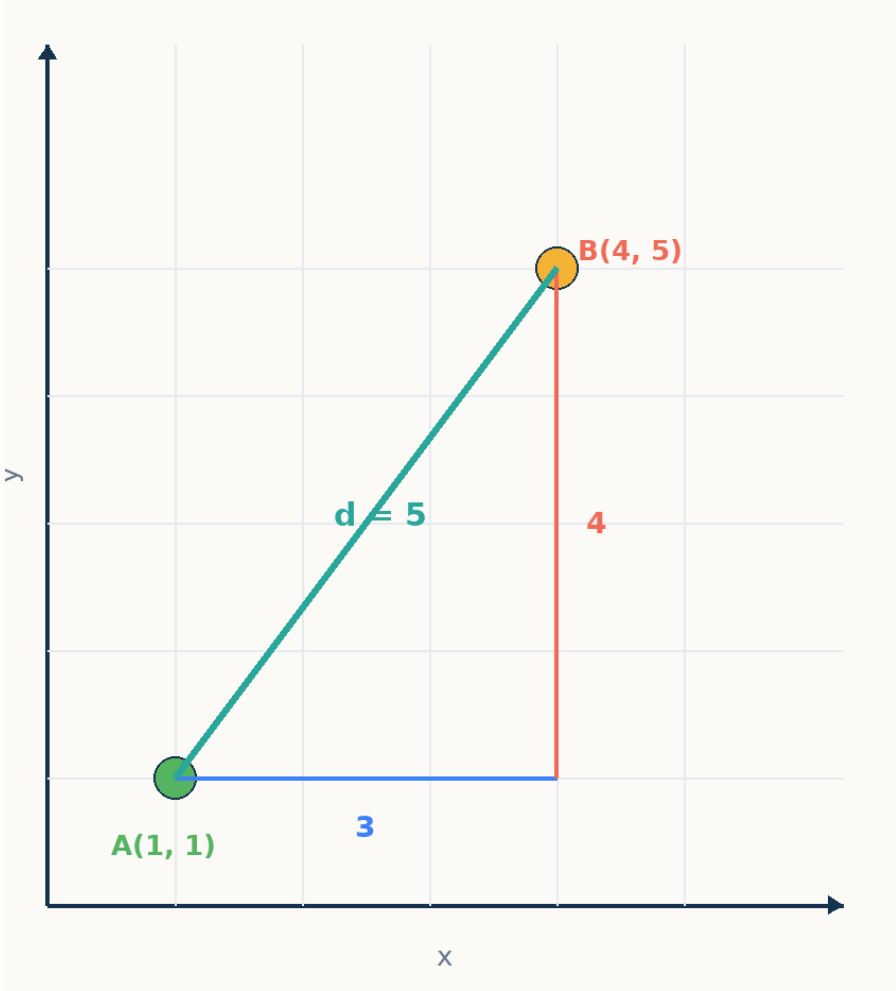
$$d(A,B) = \sqrt{((x_2 - x_1)^2 + (y_2 - y_1)^2)}$$

Пример

A(1,1), B(4,5): разности равны 3 и 4, расстояние равно 5.

Смысл

Чем меньше расстояние, тем объекты считаются более похожими.



Численный пример: исходные данные

Определим класс объекта X при k = 3

Класс A

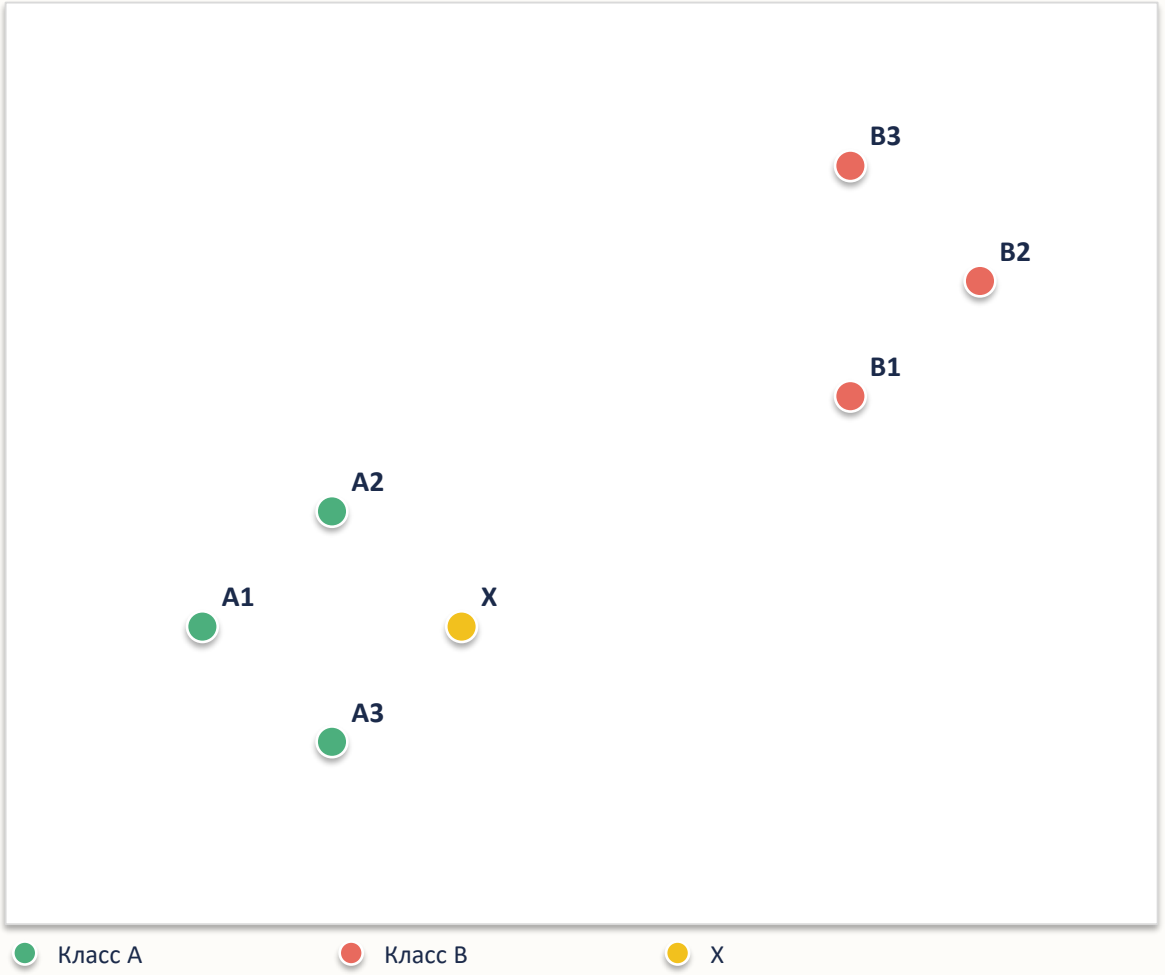
A1(1,2), A2(2,3), A3(2,1)

Класс B

B1(6,4), B2(7,5), B3(6,6)

Новый объект

X(3,2), класс неизвестен. Нужно выбрать A или B.



Численный пример: считаем расстояния

Показываем расчёт так, чтобы было понятно вручную

$$d(X,A2) = \sqrt{(3-2)^2 + (2-3)^2} \approx 1.41$$

$$d(X,A3) = \sqrt{(3-2)^2 + (2-1)^2} \approx 1.41$$

$$d(X,A1) = \sqrt{(3-1)^2 + (2-2)^2} = 2$$

Три ближайших

A2, A3 и A1 имеют наименьшие расстояния до X.

Все 3 соседа относятся к классу A

Объект	Класс	Расстояние	Место
A2	A	1.41	1
A3	A	1.41	2
A1	A	2.00	3
B1	B	3.61	4
B2	B	5.00	5
B3	B	5.00	6

Голосование и результат

Новый объект получает класс большинства соседей

k = 3

Берём ровно три ближайших объекта.

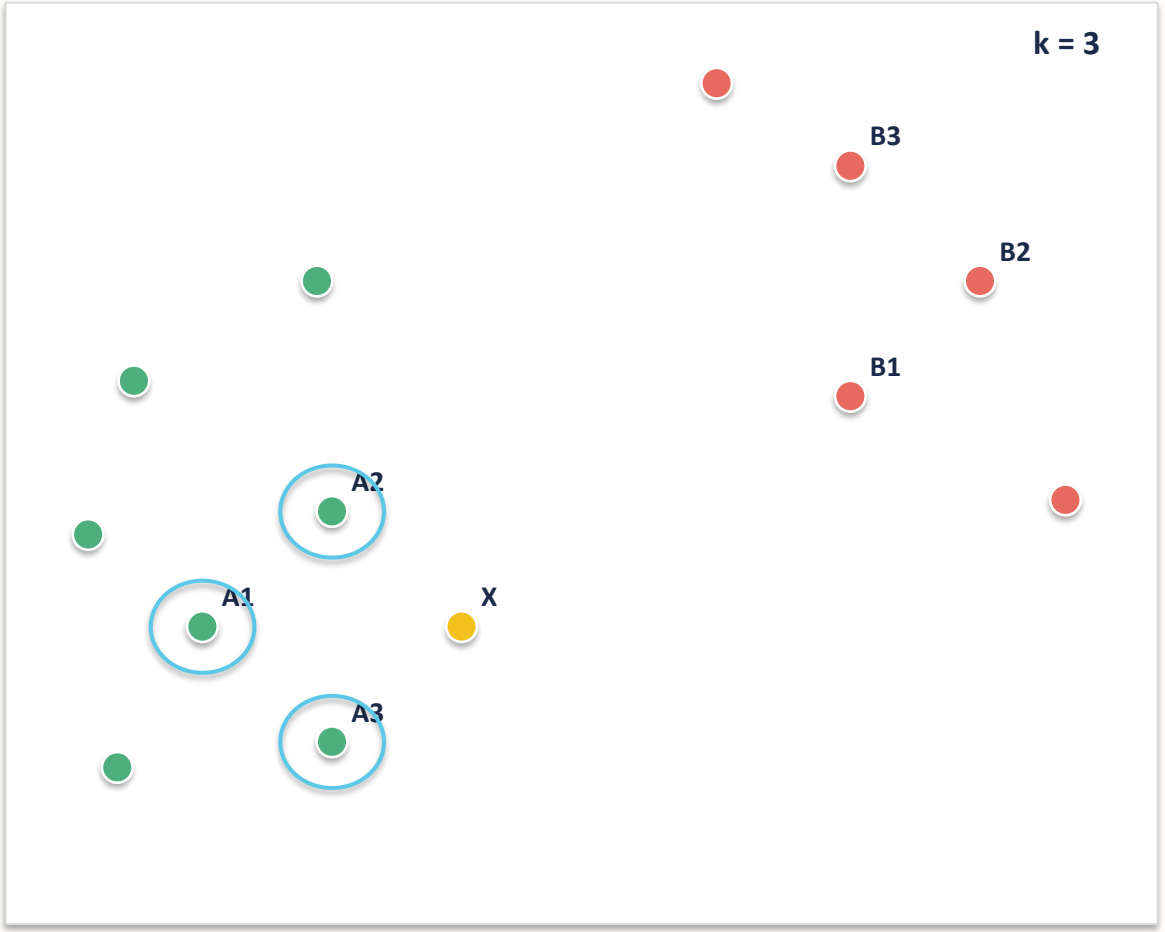
Голоса

A: 3 голоса, B: 0 голосов.

Ответ: X → класс A

A: 3

B: 0



k-NN для регрессии

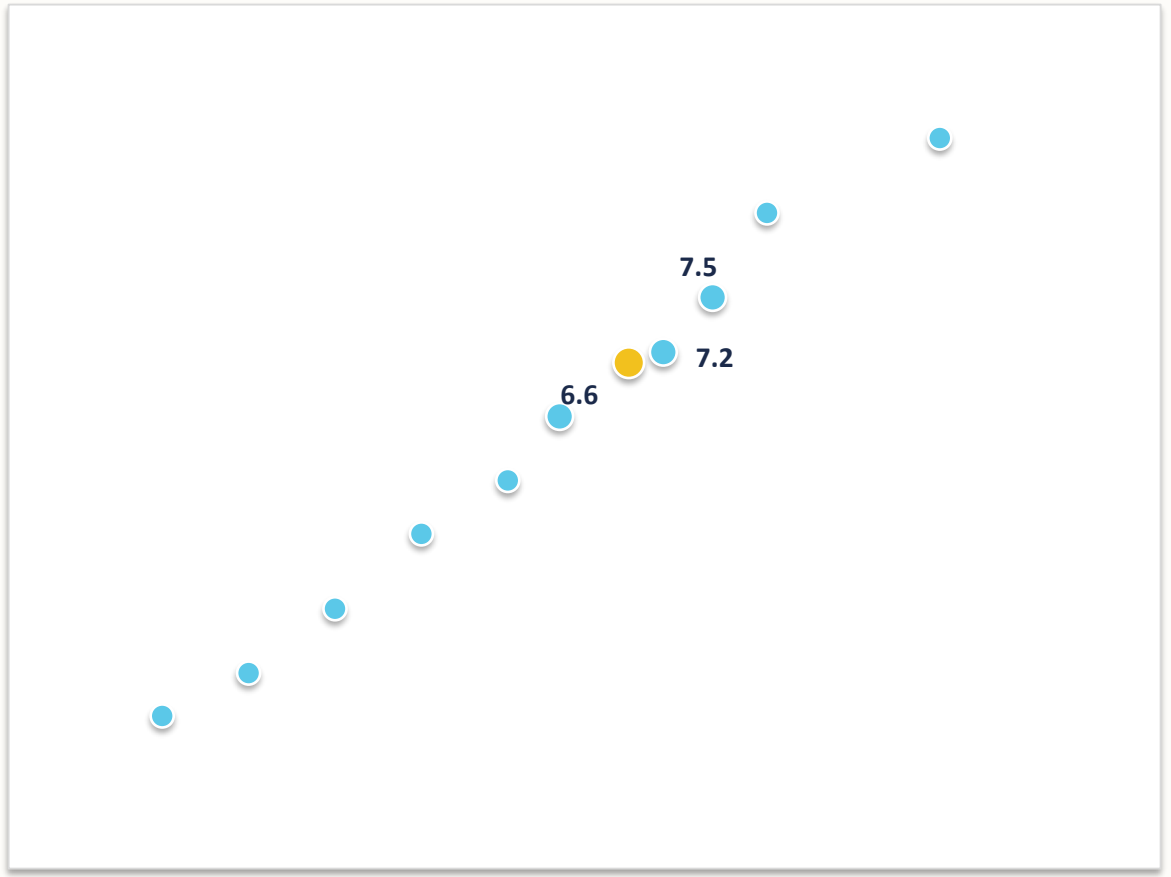
Когда нужно предсказать число, а не класс

Пример

Прогноз цены квартиры по похожим объектам.

$$\hat{y} = (6.6 + 7.2 + 7.5) / 3 = 7.1$$

В регрессии k-NN усредняет ответы соседей



Прогноз = 7.1 млн ₽

Как влияет выбор k

Маленькое k чувствительно к шуму, большое k сильнее усредняет

Маленькое k

Локальная модель, сильная чувствительность к выбросам.

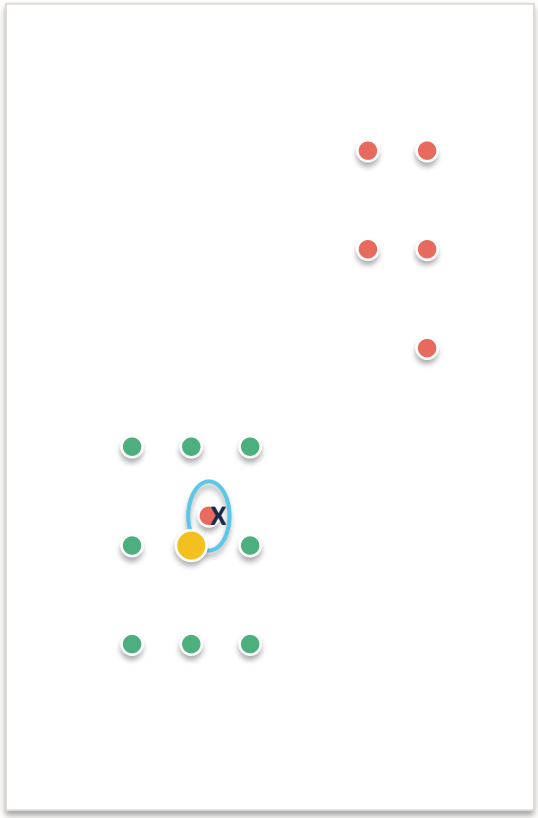
Среднее k

Обычно лучший баланс между шумом и обобщением.

Большое k

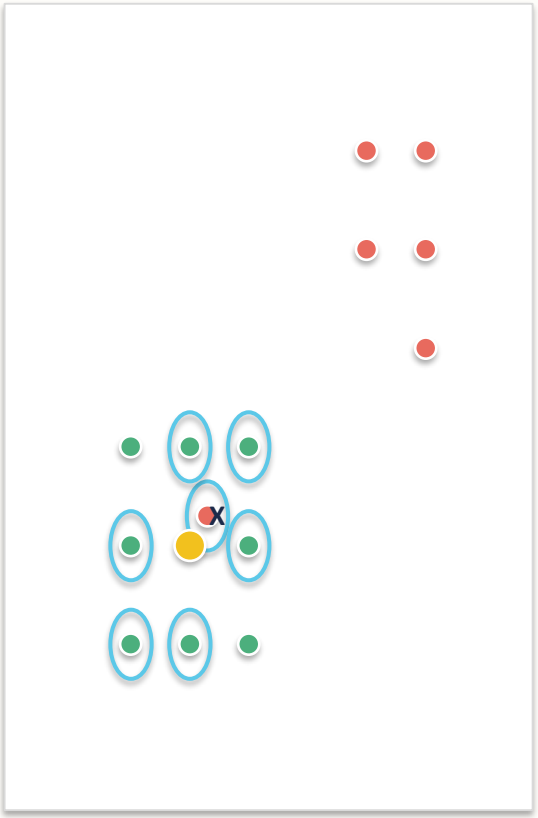
Устойчивее, но может потерять локальную структуру данных.

k = 1



Решение: класс B (ошибка)

k = 7



Решение: класс A (верно)

Масштабирование признаков

Признаки должны быть сопоставимы по масштабу

Проблема

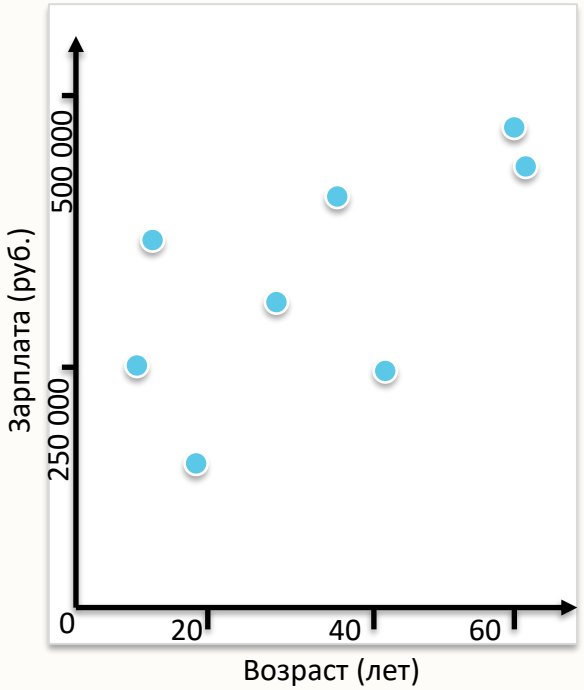
Возраст: 18–60, зарплата: 30 000–300 000. Зарплата может полностью доминировать.

Решение

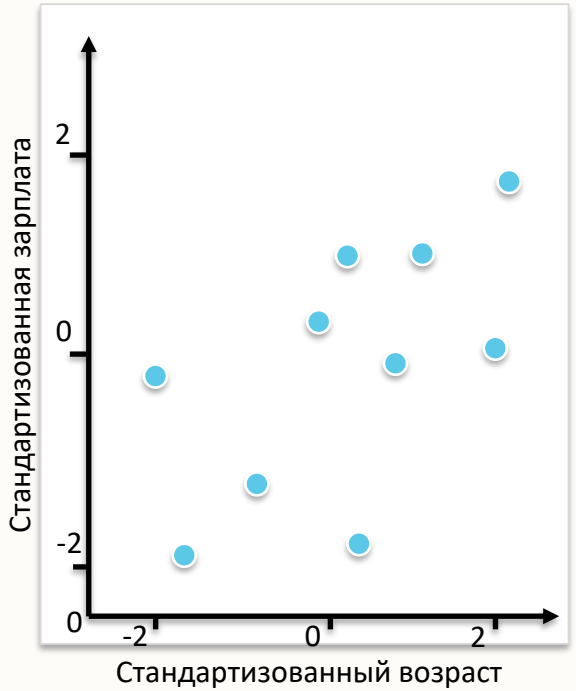
StandardScaler приводит признаки к единому масштабу: среднее 0, стандартное отклонение 1.

Без масштабирования k-NN может работать некорректно

До масштабирования



После StandardScaler



Взвешенный k-NN

Ближние соседи могут влиять сильнее дальних

Обычный k-NN

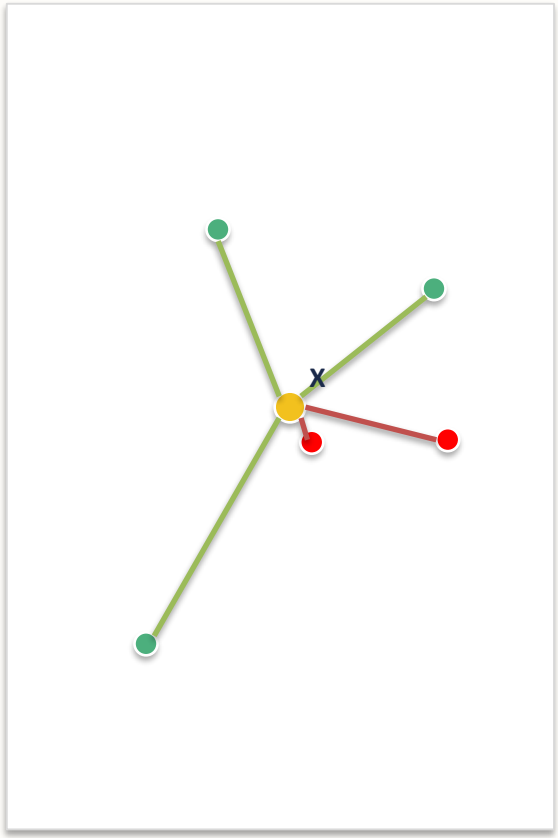
Каждый сосед имеет один голос, даже если один объект намного ближе другого.

Взвешенный k-NN

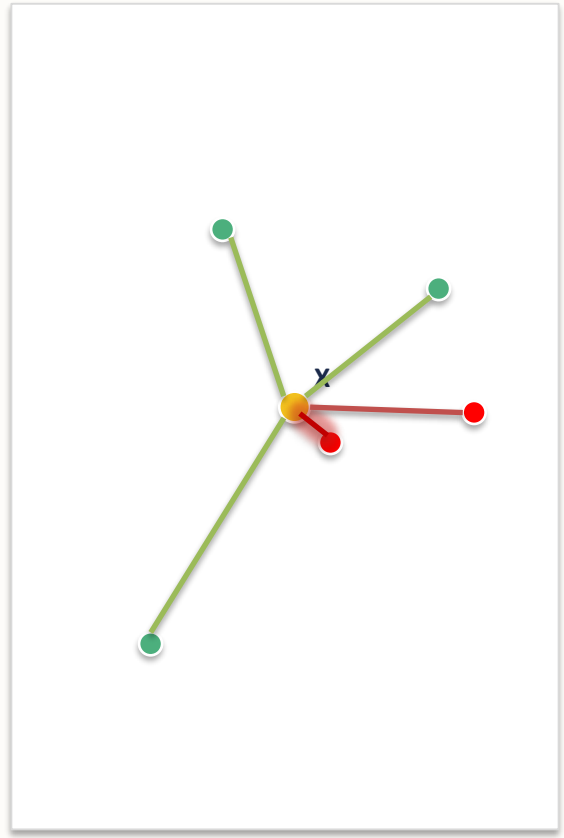
Вес соседа зависит от расстояния: чем ближе объект, тем сильнее его вклад.

```
KNeighborsClassifier(
    n_neighbors=5,
    weights="distance"
)
```

Обычный k-NN



Взвешенный k-NN



Чем ближе сосед, тем больше его вклад

Ленивое обучение и сложность

k-NN почти не обучается заранее, но активно считает при прогнозе

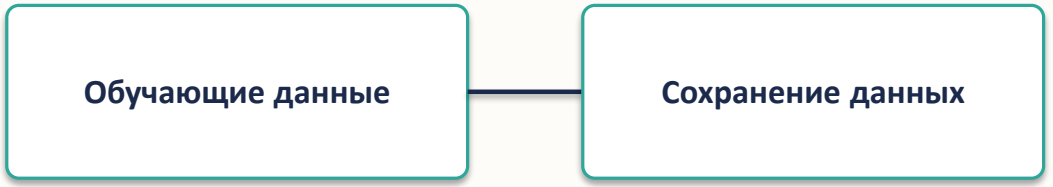
fit()

Сохранить обучающие данные. Быстро, но нужна память.

predict()

Сравнить новый объект с обучающими объектами. Может быть медленно.

Для полного перебора: память O(n·d), прогноз O(n·d)



почти нет вычислений



основная вычислительная нагрузка — здесь

Преимущества и недостатки

Когда метод удобен, а когда стоит быть осторожнее

Преимущества

- Очень простая идея
- Работает для классификации и регрессии
- Нет долгого этапа обучения
- Может описывать нелинейные границы

Недостатки

- Медленный прогноз на больших данных
- Нужно хранить обучающую выборку
- Чувствителен к масштабу признаков
- Сложно работает в высокой размерности

k-NN хорош, когда понятие «похожести» действительно отражает смысл задачи.

Сравнение с альтернативами

k-NN — не универсальный лучший алгоритм, а один из вариантов



Logistic Regression

Быстро, интерпретируемо

Линейная граница



Decision Tree

Простые правила

Легко переобучается



SVM

Сильная граница

Сложнее настройка



k-NN

Простой локальный метод

Зависит от соседей

Самостоятельная реализация на Python

Код должен запускаться в реальном времени

Что реализовано

Расчёт расстояний, сортировка соседей, голосование и регрессия.

Что можно менять

Значение k, координаты нового объекта, набор данных, режим classification/regression.

```
$ python src/main.py
```

```
$ python src/main.py

k = 3
X = (3, 2)

Ближайшие соседи:
A2  1.414
A3  1.414
A1  2.000

Голоса: A = 3, B = 0
Прогноз: A
```

Live-demo: меняем входные данные и сразу видим новый результат

1. Запуск

Показать исходный прогноз для X и k = 3.

2. Изменить k

Например, заменить k = 3 на k = 5.

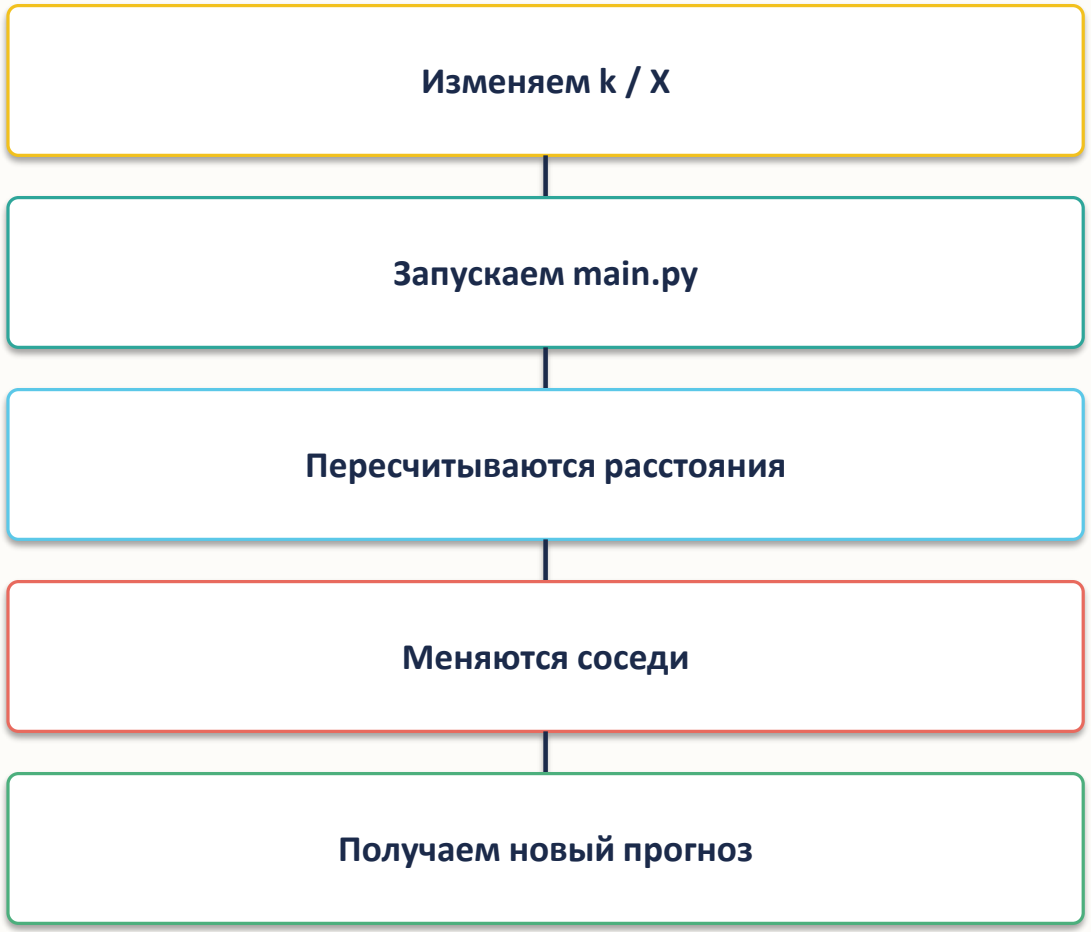
3. Изменить X

Переместить новый объект ближе к другому классу.

4. Повторный запуск

Показать новые расстояния, соседей и прогноз.

Все параметры меняются непосредственно в src/main.py.



Итоги

Идея

Прогноз строится по ближайшим похожим объектам.

Ключевые параметры

k, метрика расстояния и масштабирование.

Практика

Метод прост, но прогноз может быть дорогим на больших данных.

Спасибо за внимание