


A scatter plot illustrating the results of a Principal Component Analysis (PCA). The plot shows four distinct clusters of data points, each represented by a different color: green, red, orange, and blue. The green cluster is located on the left side of the plot, while the red, orange, and blue clusters are more centrally located and overlap significantly. The background features a light gray grid. The title 'Principal component analysis (PCA)' is overlaid in large, bold, black text across the center of the plot.

Principal component analysis (PCA)

Выполнили: Шутова Ю.
Воронцов А.


Задача PCA

Проблемы датасетов в машинном обучении (МО):


1. Избыточная размерность данных.
2. Сильно коррелирующие признаки.
3. Сложность визуализация данных.

Задача, которую решает PCA: сжать N исходных признаков до K новых ($K \ll N$), сохранив максимум полезной информации (дисперсии).

Цель: найти новое, более компактное описание наших данных.




Как работает метод главных компонент?



Original Variables

PCA
→




Principle Components

Ковариационная матрица - это квадратная матрица, показывающая ковариацию между каждой парой переменных в наборе данных. По диагонали матрицы расположены дисперсии каждой отдельной переменной. Она описывает структуру линейных взаимосвязей в данных.

В контексте PCA, **собственные векторы ковариационной матрицы** — это направления новых осей (главных компонент), вдоль которых наблюдается максимальная дисперсия. Собственные значения показывают, какая доля общей дисперсии приходится на каждый из этих векторов (т. е. насколько важна каждая компонента).

Сингулярное разложение - метод разложения (факторизации) матрицы на три другие матрицы. В контексте PCA, SVD является численно стабильным и эффективным способом нахождения главных компонент без явного вычисления ковариационной матрицы.

Матрица Грама - матрица попарных скалярных произведений строк датасета. В контексте PCA, это альтернативный метод поиска главных компонент, который может быть полезен, когда записей в датасете больше, чем признаков



Пошаговый алгоритм на примере

Задача: имеется $n = 4$ студентов, их успеваемость измеряется по 2-ум предметам. Требуется рассчитать индекс успеваемости.

Шаг 1. Центрирование и нормализация данных.

$$\bar{X}_j = \frac{1}{n} \sum_{i=1}^n X_{ij} \quad :$$

$$\bar{X} = \frac{2+3+7+8}{4} = 5$$

$$\bar{X} = \frac{3+4+5+8}{4} = 5$$

Далее рассчитываем элементы центрированной матрицы:

$$x_{ij} = X_{ij} - \bar{X}_j \quad :$$

$$\text{Student } 1 : x_1 = 2 - 5 = -3 \quad x_1 = 3 - 5 = -2$$

$$2 : x_2 = -2 \quad x_2 = -1$$

$$3 : x_3 = 2 \quad x_3 = 0$$

$$4 : x_4 = 3 \quad x_4 = 3$$

Student	Python	R
1	2	3
2	3	4
3	7	5
4	8	8

Шаг 2. Расчет ковариационной матрицы. Считаем дисперсии и ковариацию.

$$\text{Var}(X_j) = \frac{1}{n-1} \sum_{i=1}^n x_{ij}^2$$

$$\text{Cov}(X, Y) = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})$$

$$D = \frac{(-3)^2 + (-2)^2 + 2^2 + 3^2}{4-1} \approx 8,67$$

$$c_{xx} = \frac{(-3)(-2) + (-2)(-1) + 2 \cdot 0 + 3 \cdot 3}{3} \approx 5,67$$

$$D = \frac{(-2)^2 + (-1)^2 + 0^2 + 3^2}{3} \approx 4,67$$

Матрица ковариации: $\Sigma = \begin{pmatrix} 8,67 & 5,67 \\ 5,67 & 4,67 \end{pmatrix}$

Шаг 3. Нахождение собственных векторов и значений.

$$\Sigma \bar{v} = \lambda \bar{v}$$

$$|\Sigma - \lambda I| = 0$$

$$\begin{pmatrix} 8,67 - \lambda & 5,67 \\ 5,67 & 4,67 - \lambda \end{pmatrix} = 0$$

$$(8,67 - \lambda)(4,67 - \lambda) - 5,67^2 = 0$$

$$\lambda_1 \approx 0,66$$

$$\lambda_2 \approx 12,68$$

$$(\Sigma - \lambda I) \bar{v} = 0$$

$$\begin{pmatrix} 8,67 - 0,66 & 5,67 \\ 5,67 & 4,67 - 0,66 \end{pmatrix} \begin{pmatrix} v_1 \\ v_2 \end{pmatrix} = 0$$


...

$$v_1 = \begin{pmatrix} 0,82 \\ 0,58 \end{pmatrix}$$

$$\text{гм } \lambda_2 = 12,68 : v_2 = \begin{pmatrix} -0,58 \\ 0,82 \end{pmatrix}$$

Шаг 4. Выбор количества компонент.

Для нашего примера можно выбрать либо одну, либо две компоненты (т.к. количество признаков всего составляет 2). Для больших датасетов используется график **scree plot**, либо **критерий Кайзера**.



$$\text{Explained Variance}_k = \frac{\lambda_k}{\sum_{j=1}^p \lambda_j}$$

$$\lambda := 12,68 + 0,66 = 13,34$$

PC 1	PC 2
$\frac{12,68}{13,34} =$	$\frac{0,66}{13,34} =$
$= 0,95$	$= 0,05$

Шаг 5. Проекция данных. Расчет приведен для PC1, аналогичным образом можно рассчитать и для PC2.

$$v_1 = \begin{pmatrix} 0,82 \\ 0,58 \end{pmatrix} \quad v_2 = \begin{pmatrix} -0,58 \\ 0,82 \end{pmatrix}.$$

$$Z = x \cdot v_{1x} + x \cdot v_{1x}$$

где PC1

$$\text{Student 1: } z_1 = -3 \cdot 0,82 + (-2) \cdot 0,58 = -3,62$$

$$2: z_2 = -2 \cdot 0,82 + \dots = -2,22$$

$$3: z_3 = 1,64$$

$$4: z_4 = 4,20$$


$$\text{Student 1: } x_1 = 2 - 5 = -3 \quad x_1 = 3 - 5 = -2$$

$$2: x_2 = -2 \quad x_2 = -1$$


$$3: x_3 = 2 \quad x_3 = 0$$

$$4: x_4 = 3 \quad x_4 = 3$$

2. Проекция PCA (PC1 vs PC2)



2. Проекция PCA (1D)
Сохранено 95.1% информации



Готовые реализации PCA

На практике PCA удобно применять через класс `PCA` из библиотеки `scikit-learn`. Достаточно указать число компонент и передать исходные данные:

```
from sklearn.decomposition import PCA

X = [[2, 3], [3, 4], [7, 5], [8, 8]]

pca = PCA(n_components=1, svd_solver="full")
X_pca = pca.fit_transform(X)

print(X_pca)                # Координаты студентов на новой оси
print(pca.explained_variance_ratio_) # [0.9507...] — около 95,1%
```

Как выбрать кол-во компонентов?

- По накопленной объяснённой дисперсии.
- По графику собственных значений — scree plot.
- По качеству дальнейшей модели.

Пример на Python

Источники

[Хендбук по ML: Матричные факторизации](#)

[Что такое PCA: понятная суть метода главных компонент](#)

[Lecture11_PCA.pptx](#)

[Principal Component Analysis Guide & Example - Statistics By Jim](#)