Федеральное государственное автономное образовательное учреждение высшего образования «Санкт-Петербургский политехнический университет Петра Великого»

ОТЧЁТ

Проект по дисциплине «Основы машинного обучения»

Определение языка короткого текста по символьным n-граммам

Выполнила: Крапивина У. О.
студентка группы 5030102/30401

Санкт-Петербург
2026

Contents

1 Введение **1**

1.1 Актуальность . . . 1

1.2 Цель и задачи . . . 1

2 Данные **1**

2.1 Датасет . . . 1

2.2 Проверка пересечения выборок . . . 2

2.3 Разведочный анализ . . . 2

3 Метод **3**

3.1 Символьные n-граммы и TF-IDF . . . 3

3.2 Классификаторы . . . 4

3.3 Baseline: word-level . . . 4

4 Эксперименты **4**

4.1 Подбор гиперпараметров . . . 4

4.2 Сравнение моделей . . . 5

4.3 Подбор C для LinearSVC . . . 5

4.4 Финальная модель . . . 6

5 Анализ результатов **6**

5.1 Финальные метрики . . . 6

5.2 Анализ ошибок . . . 7

5.3 Интерпретация n-грамм . . . 7

5.4 Роль алфавита: транслитерация ru → лат. . . . 8

6 Устойчивость к длине и опечаткам **9**

6.1 Эксперимент с длиной . . . 9

6.2 Эксперимент с опечатками . . . 10

7 Заключение **11**

1 Введение

1.1 Актуальность

Задача автоматического определения языка текста (language identification, LID) возникает в широком круге прикладных сценариев: модерация пользовательского контента, маршрутизация обращений в поддержку, предобработка данных для машинного перевода, аналитика социальных сетей. Особую сложность представляют *короткие тексты* — сообщения, комментарии, поисковые запросы, — где классические методы, опирающиеся на словари и токенизацию, работают плохо из-за отсутствия полных слов, опечаток и смешения языков.

1.2 Цель и задачи

Цель работы — построить и исследовать классификатор языка короткого текста на основе символьных n-грамм, оценить его точность, интерпретируемость и устойчивость к длине и опечаткам.

Задачи:

1. Провести разведочный анализ данных (EDA) и обосновать выбор символьных n-грамм.
2. Построить baseline (MultinomialNB) и подобрать гиперпараметры (`ngram_range`, `min_df`).
3. Сравнить MNB, LogisticRegression и LinearSVC, выбрать финальную модель.
4. Оценить качество (accuracy, macro-F1, confusion matrix), проанализировать ошибки.
5. Интерпретировать модель через веса n-грамм; проверить роль алфавита.
6. Провести ключевой эксперимент: сравнить char n-grams и word-level на коротких текстах и при опечатках.

2 Данные

2.1 Датасет

Использован публичный датасет `papluca/language-identification` (Hugging Face), содержащий 20 языков и короткие тексты из домена отзывов. Для проекта выбраны **8 языков**: `en, fr, de, es, it, ru, pt, nl`. Итоговые размеры выборок:

- train: 28 000 (по 3 500 на язык);
- validation: 4 000 (по 500);
- test: 4 000 (по 500).

2.2 Проверка пересечения выборок

Для оценки риска утечки данных проверено пересечение текстов между train и test. Оно составило **111 текстов из 4 000 в test** (2.8%). Все совпадения относятся к типовым коротким фразам из домена отзывов (например, `'Een man eet.'`, `'Un uomo sta tagliando una cipolla.'`), которые встречаются в датасете в нескольких вариантах. Датасет `papluca/language-identification` используется в официальном разбиении, поэтому пересечение сохранено; при интерпретации метрик его вклад следует учитывать как потенциальное завышение accuracy на **порядка 0.3 п.п.** (оценка сверху: 111/4000 при условии, что все они распознаны верно). Для экспериментов с обрезкой и опечатками (раздел 6) пересечение не играет роли: модели на этих тестах проверяют устойчивость к изменению входа, а не точность на «чистом» распределении.

2.3 Разведочный анализ

На рис. 1 показано распределение классов. Выборки сбалансированы по классам, поэтому accuracy удобно использовать для общей оценки качества. Дополнительно рассчитывается macro-F1, позволяющая оценить качество распознавания каждого языка с одинаковым весом (при идеальном балансе классов обе метрики численно совпадают).

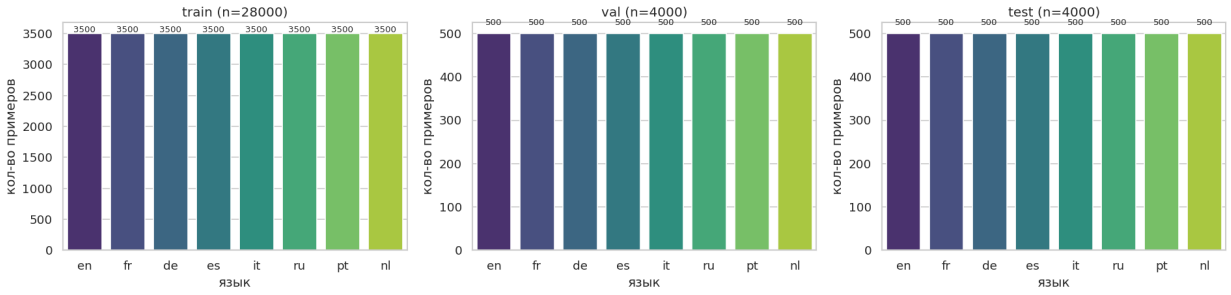


Figure 1: Распределение классов в train / validation / test.

Распределение длин текстов (рис. 2) показывает, что тексты разнородны: медиана — от 54 символов (nl, it, pt) до 154 (de); есть длинные примеры до 2 400 символов. Доля текстов короче 20 символов мала (0–3.7%), поэтому отдельный эксперимент по коротким текстам проводится искусственной обрезкой (раздел 6).

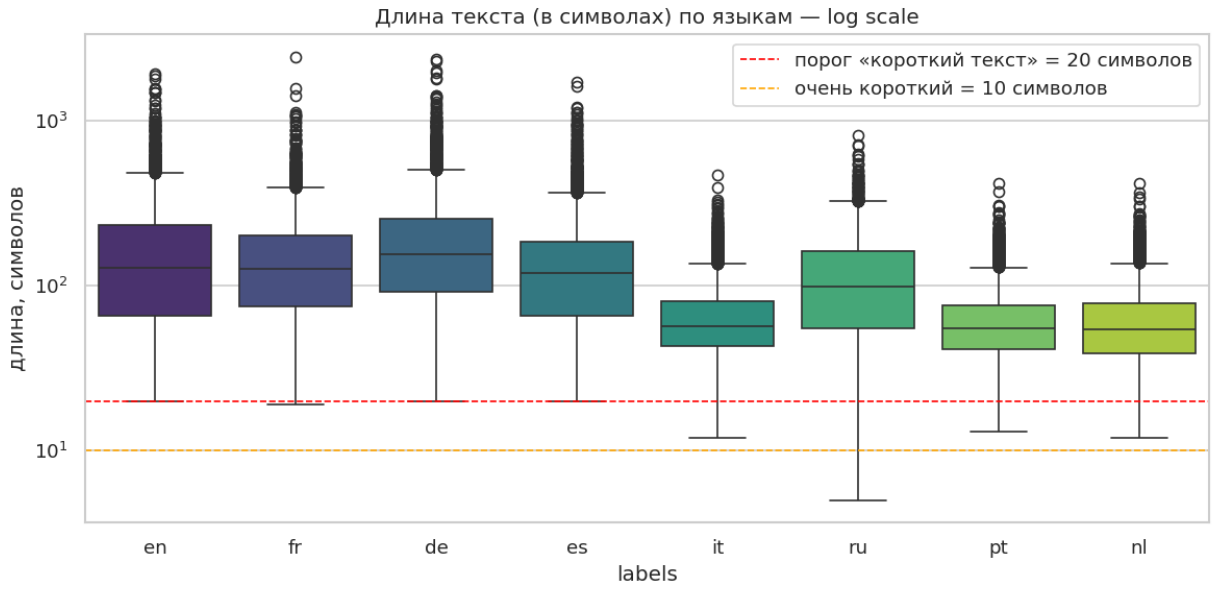


Figure 2: Распределение длины текстов по языкам (логарифмическая шкала).

Уже на этапе EDA видно, что **символьные триграммы сами по себе различают языки**:

- en: `' th'`, `'the'`, `'ing'`;
- de: `'ich'`, `'sch'`, `'ein'`, `'cht'`;
- fr: `'le '`, `'es '`, `'nt '`, `'ne '`;
- es: `'que'`, `'ue '`, `' qu'`;
- it: `' di'`, `'to '`, `'la '`;
- pt: `' de'`, `'os '`, `'est'`;
- nl: `'en '`, `'een'`, `'an '`;
- ru: кириллические триграммы `' пр'`, `'ени'`, `'ого'`.

Это обосновывает выбор метода: TF-IDF по символьным n-граммам + линейный классификатор.

3 Метод

3.1 Символьные n-граммы и TF-IDF

Текст разбивается на символьные n-граммы (`analyzer='char_wb'`, учитывающий границы слов), после чего взвешивается по схеме TF-IDF:

$$\text{tfidf}(t, d) = \text{tf}(t, d) \cdot \log \frac{1 + N}{1 + \text{df}(t)} + 1, \tag{1}$$

где $\mathrm{tf}(t, d)$ — частота n-граммы t в документе d, $\mathrm{df}(t)$ — число документов, содержащих t, N — общее число документов. Используется `sublinear_tf=True`: $\mathrm{tf} \to 1 + \log \mathrm{tf}$.

3.2 Классификаторы

Сравниваются три модели:

- **MultinomialNB** — генеративная модель, предполагающая независимость признаков;
- **LogisticRegression** — дискриминативная модель, оптимизирует log-loss;
- **LinearSVC** — линейный SVM, максимизирует margin.

3.3 Baseline: word-level

Для сравнения строится word-level пайплайн (`analyzer='word'`, `ngram_range=(1,2)`, `min_df=2`) с LinearSVC.

4 Эксперименты

4.1 Подбор гиперпараметров

Перебраны 15 конфигураций `ngram_range` × `min_df` для MNB (табл. 1).

Table 1: Результаты перебора гиперпараметров (MNB, validation).

`ngram_range`	`min_df`	features	val acc	val macro-F1
(2,4)	5	53 037	0.9975	0.9975
(1,4)	5	53 183	0.9973	0.9972
(2,5)	5	102 833	0.9968	0.9967
(1,4)	3	69 150	0.9965	0.9965
(1,3)	5	17 154	0.9963	0.9962
(1,3)	2	24 095	0.9948	0.9947
(1,2)	5	2 791	0.9898	0.9897

Ключевые наблюдения:

- Оптимум — `(1,4)` или `(2,4)` при `min_df=5`.
- Униграммы **не критичны**, если алфавиты различаются (триграммы уже несут весь сигнал).
- `min_df` монотонно улучшает качество при 2→5.

На рис. 3 приведена тепловая карта.

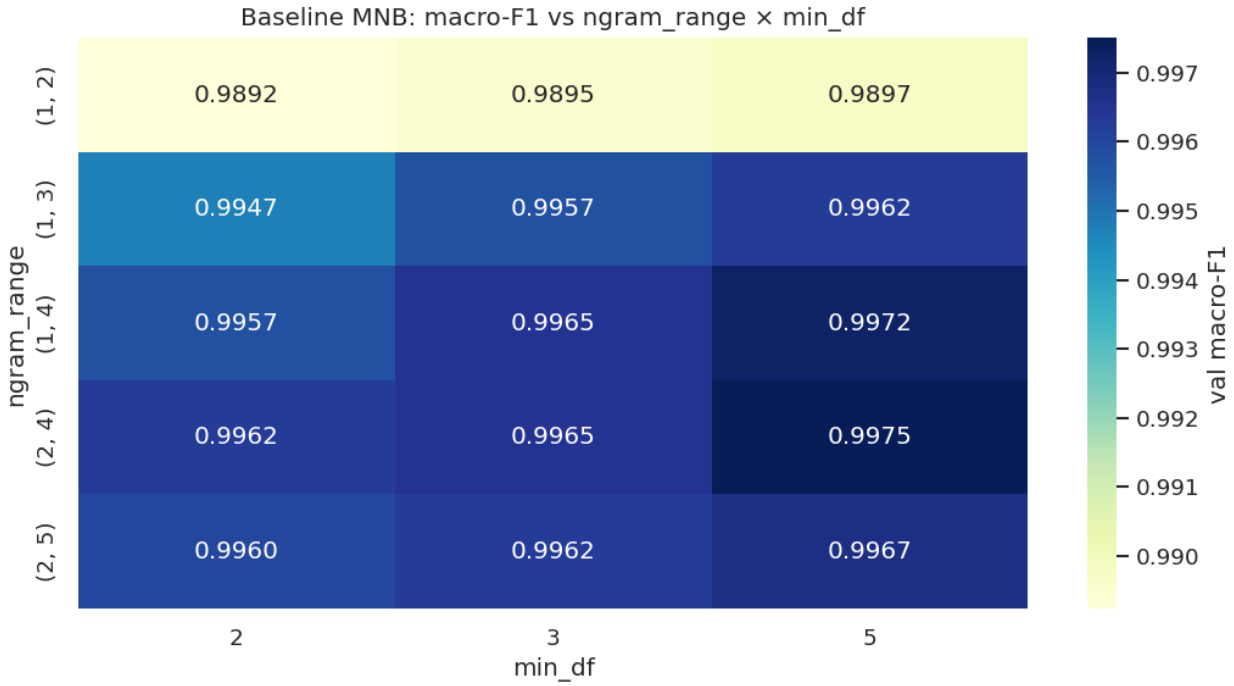


Figure 3: Macro-F1 в зависимости от `ngram_range` и `min_df`.

4.2 Сравнение моделей

В табл. 2 — сравнение MNB, LogReg и LinearSVC на двух лучших конфигурациях.

Table 2: Сравнение моделей (validation).

Конфигурация	Модель	features	val acc	val macro-F1	время, с
(1,4), min_df=5	LinearSVC	53 183	**0.9995**	**0.9995**	13.4
(2,4), min_df=5	LinearSVC	53 037	**0.9995**	**0.9995**	11.6
(1,4), min_df=5	LogReg	53 183	0.9985	0.9985	26.1
(2,4), min_df=5	LogReg	53 037	0.9983	0.9983	16.6
(2,4), min_df=5	MNB	53 037	0.9975	0.9975	10.2

Вывод: LinearSVC > LogReg > MNB. Разница — 8–16 примеров из 4 000. На этом датасете все три модели применимы; SVC предпочтителен по F1 и скорости.

4.3 Подбор C для LinearSVC

Кривая качества по C (рис. 4) имеет широкое плато на $C \in [0.5, 10]$. На validation наилучшее значение macro-F1 достигнуто при $C = 0.5$ (0.99975), однако разница с $C = 1.0$ (0.99950) составляет ровно один объект из 4 000, что лежит в пределах статистического шума. Для финальной модели сохранено $C = 1.0$ как практически равноценное значение. Гиперпараметр, таким образом, не является критичным на данной задаче.

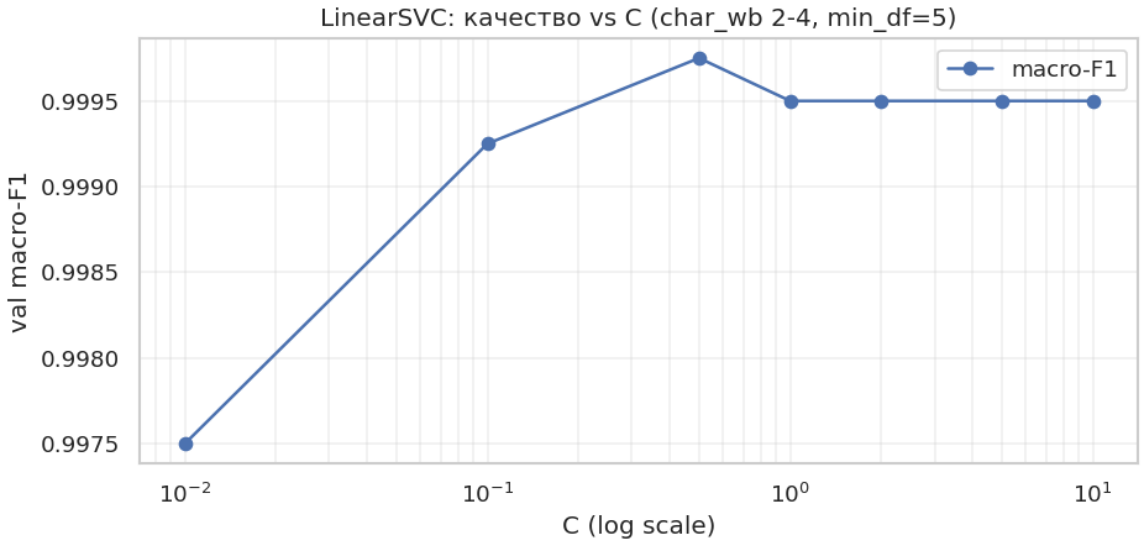


Figure 4: Влияние C на macro-F1 (LinearSVC, char_wb 2–4, min_df=5).

4.4 Финальная модель

По результатам сравнения выбрана конфигурация: **LinearSVC, $C = 1$, char_wb (2,4), min_df=5, sublinear_tf**. Конфигурация (1,4) показала идентичное качество на validation после округления (0.9995), однако (2,4) предпочтена, поскольку исключает униграммы и формирует более компактный и интерпретируемый словарь. Результаты на test: **accuracy = 0.9990, macro-F1 = 0.9990**.

5 Анализ результатов

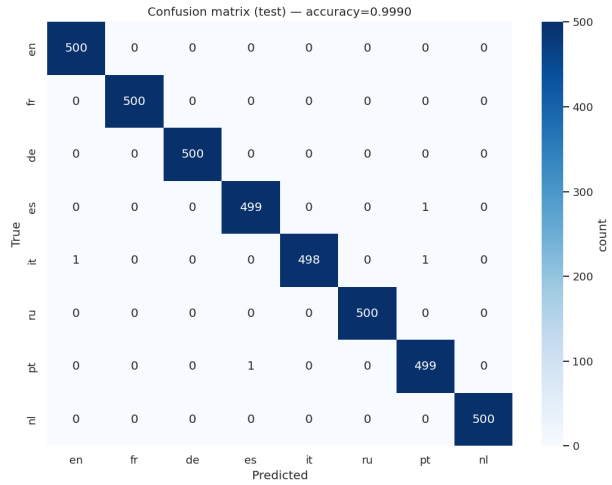
5.1 Финальные метрики

В табл. 3 — classification report на test.

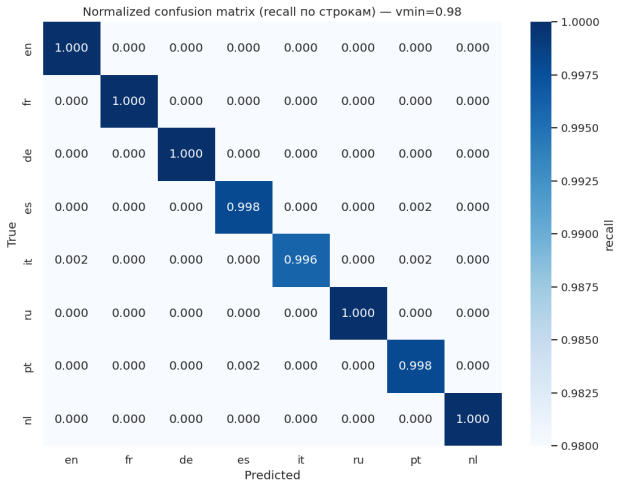
Table 3: Classification report на test (LinearSVC, $C = 1$, char_wb (2,4), min_df=5).

Язык	precision	recall	f1-score	support
de	1.0000	1.0000	1.0000	500
en	0.9980	1.0000	0.9990	500
es	0.9980	0.9980	0.9980	500
fr	1.0000	1.0000	1.0000	500
it	1.0000	0.9960	0.9980	500
nl	1.0000	1.0000	1.0000	500
pt	0.9960	0.9980	0.9970	500
ru	1.0000	1.0000	1.0000	500
accuracy		0.9990		4 000
macro avg	0.9990	0.9990	0.9990	4 000

Confusion matrix (абсолютные и нормированные значения) — на рис. 5a и 5b.



(a) Абсолютные значения



(b) Нормированные (vmin=0.98)

Figure 5: Confusion matrix на test.

5.2 Анализ ошибок

Всего **4 ошибки из 4 000** (0.10%). Каждая иллюстрирует определённое ограничение метода:

1. `exactamente como descrito` (es → pt). *Объективная неоднозначность:* все слова идентичны в pt и es.

2. `Rev's Early Reads: 2 marzo` (it → en). *Смешанный язык:* английское название + итальянская дата.

3. `Talvez isto possa funcionar para si.` (pt → es). *Слабый сигнал:* различающие маркеры (`isto`, `possa`) — редкие, взвешены низко.

4. `Le tombe segnalate da Albuquerque...` (it → pt). *Имена собственные* «перебивают» сигнал.

Ни одна ошибка не вызвана дефектом метода: модель достигла потолка, определяемого данными.

5.3 Интерпретация n-грамм

Для интерпретации модели используются коэффициенты `LinearSVC`. В многоклассовой постановке решается задача «один против всех»: каждый язык k получает собственный вектор весов $\mathbf{w}_k$. Большой положительный коэффициент $w_{k,t}$ означает, что n-грамма t *поддерживает* класс k в его линейном классификаторе, но не гарантирует, что признак уникален для этого языка. Признаки с высоким весом могут также отражать форматные и орфографические особенности (пунктуацию, пробельно-буквенные сочетания), а не только собственно языковые закономерности.

Примеры наиболее весомых n-грамм для каждого языка приведены в табл. 4. Отметим важную особенность токенизатора `char_wb`: он добавляет пробелы по краям слов. Поэтому признаки `'␣п'` и `'i␣'` имеют длину 2 (пробел + буква), а не 1. Программная проверка словаря финальной модели подтверждает, что `min_len=2`, `max_len=4`, `count(len==1)=0` — односимвольных признаков в словаре нет.

Table 4: Примеры наиболее весомых n-грамм финальной модели LinearSVC (char_wb 2–4, min_df=5). Символ ␣ обозначает пробел.

Язык	Наиболее весомые n-граммы (вес)
de	`'ei'`(1.47), `'ch'`(1.36), `'ich'`(1.12), `'ein'`(1.10), `'ung'`(0.96), `'sch'`(0.90), `'t␣'`(0.95)
en	`'th'`(1.84), `'y␣'`(1.63), `'d␣'`(1.51), `'␣it'`(1.49), `'ed␣'`(1.46), `'␣to␣'`(1.20)
es	`'␣el␣'`(1.75), `'␣y␣'`(1.71), `'␣se␣'`(1.39), `'␣no␣'`(1.26), `'dad␣'`(1.04)
fr	`'pas␣'`(1.61), `'ur␣'`(1.13), `'ré'`(1.09), `'␣à␣'`(1.07), `'ou'`(1.05)
it	`'i␣'`(3.27), `'di␣'`(1.89), `'␣di␣'`(1.73), `'␣il␣'`(1.50), `'ato'`(1.38)
nl	`'aa'`(2.39), `'ee'`(1.94), `'ij'`(1.83), `'oo'`(1.58), `'oe'`(1.47)
pt	`'␣o␣'`(2.79), `'m␣'`(2.39), `'ão'`(2.07), `'␣do␣'`(1.81), `'lh'`(1.38)
ru	`'␣.␣'`(1.36), `'␣.'`(1.28), `'␣в'`(1.11), `'␣п'`(0.94), `'pa'`(0.68)

Модель выделяет как **лингвистические**, так и **орфографические и форматные** признаки. К первым относятся, например, артикли `'␣el␣'` (es), `'␣il␣'` (it), `'␣o␣'` (pt), характерные дифтонги `'aa'`, `'ee'`, `'ij'` (nl) и суффикс `'ão'` (pt); сочетание `'ij'` характерно для нидерландского языка, хотя встречается и в других языках и контекстах. Ко вторым — пунктуационные и пробельные сочетания, такие как `'␣.␣'` для русского языка: они отражают оформление текста (пробел вокруг точки), а не специфическую языковую закономерность. Heatmap весов — на рис. 6.

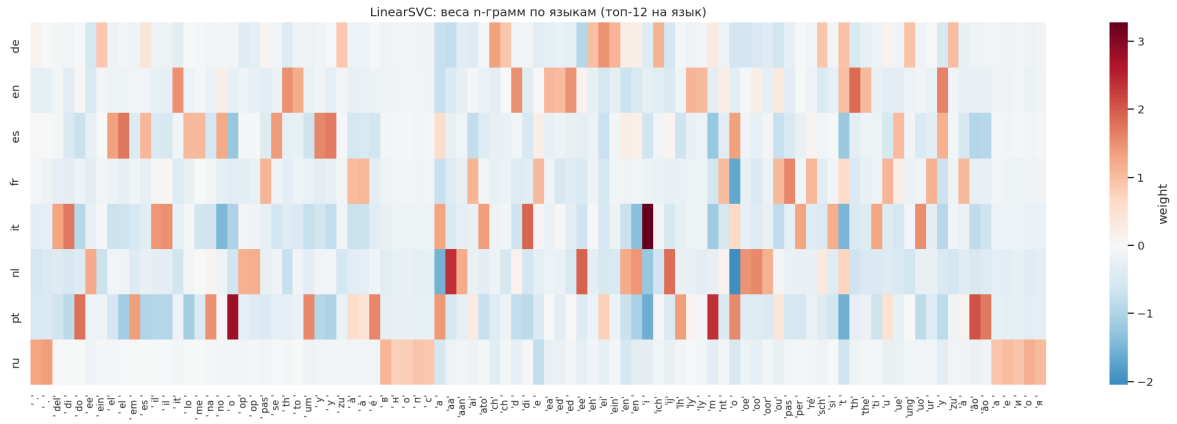


Figure 6: Веса n-грамм по языкам (красный — «за», синий — «против»).

5.4 Роль алфавита: транслитерация ru → лат.

При транслитерации тестовых `ru`-текстов в латиницу точность распознавания обученной модели падает с **1.000 до 0.000**. Все 500 текстов переклассифицированы как `nl` (188), `it` (185),

pt (116). Это показывает **высокую зависимость модели от символьных признаков исходного алфавита** и её ограниченную способность обрабатывать транслитерированные тексты без дополнительного обучения. Эксперимент *не доказывает*, что модель не использует языковые закономерности: он одновременно меняет алфавит и распределение входных признаков. Для разделения этих эффектов можно обучить дополнительную модель на транслитерированных русских текстах и сравнить её качество с моделью на кириллице.

6 Устойчивость к длине и опечаткам

6.1 Эксперимент с длиной

Тексты test обрезаны до N символов, предсказания сделаны обеими моделями (табл. 5).

Table 5: Accuracy в зависимости от длины текста: char n-grams vs word-level.

Длина (симв.)	char acc	char F1	word acc	word F1
5	**0.7688**	0.7705	0.6378	0.6663
10	**0.8960**	0.8968	0.7917	0.8014
15	**0.9492**	0.9496	0.8755	0.8792
20	**0.9745**	0.9746	0.9268	0.9282
30	**0.9905**	0.9905	0.9678	0.9679
50	**0.9982**	0.9983	0.9900	0.9900
100	**0.9990**	0.9990	0.9952	0.9953
200	**0.9990**	0.9990	0.9952	0.9953

Кривые на рис. 7 показывают, что с увеличением длины текста преимущество символьных n-грамм **монотонно сокращается**: 13.1 п.п. при длине 5 символов, 10.4 п.п. при 10, 4.8 п.п. при 20, 0.8 п.п. при 50 и 0.4 п.п. при 100–200. На рассмотренной выборке разрыв не исчезает полностью, но к длине ≥ 50 символов становится небольшим. *Ограничение эксперимента:* искусственная обрезка моделирует потерю начала текста, а не все возможные типы коротких сообщений (эмодзи, аббревиатуры, транслит), поэтому результаты следует интерпретировать как оценку устойчивости к сокращению входа.

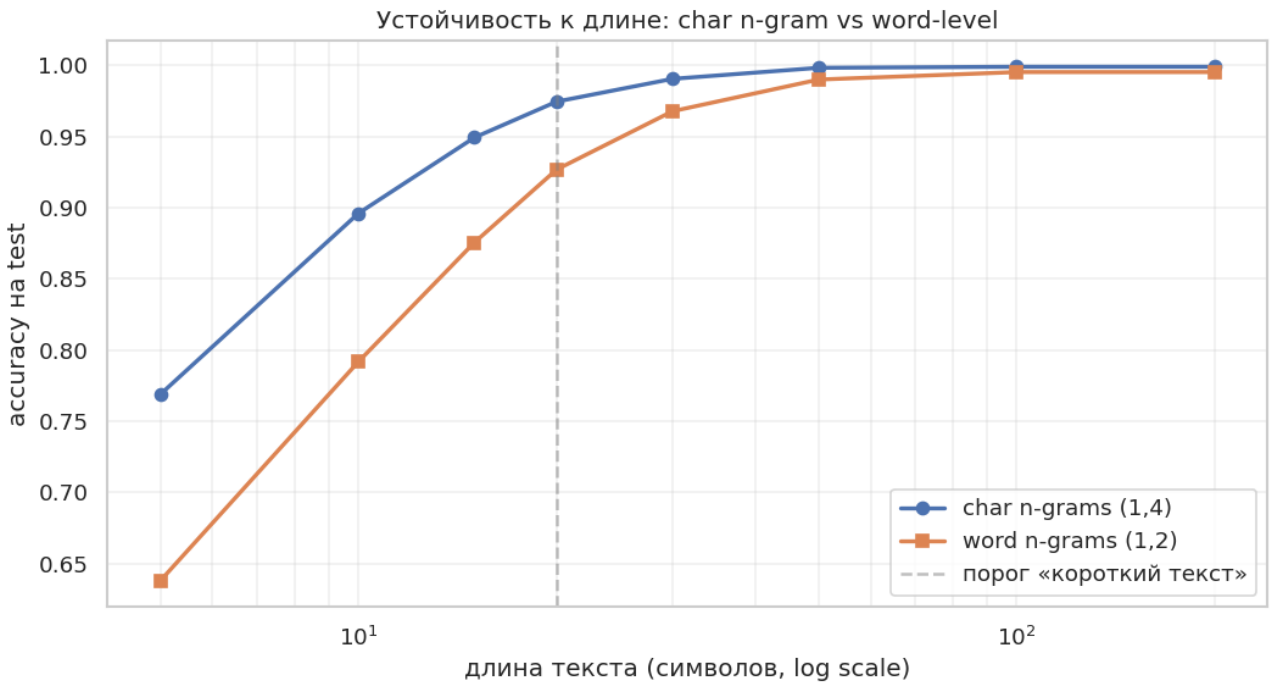


Figure 7: Accuracy vs длина текста (логарифмическая шкала).

6.2 Эксперимент с опечатками

В тестовые тексты добавлены случайные опечатки (замена / удаление / перестановка) с вероятностью p (табл. 6).

Table 6: Accuracy при добавлении опечаток: char n-grams vs word-level.

Доля опечаток	char acc	word acc	разрыв, п.п.
0%	**0.9990**	0.9952	+0.4
5%	**0.9985**	0.9865	+1.2
10%	**0.9942**	0.9448	+4.9
20%	**0.9770**	0.8488	+12.8
30%	**0.9442**	0.6798	+26.4
40%	**0.8375**	0.4900	+34.7
50%	**0.7042**	0.3418	+36.2

Кривые — на рис. 8. При 30%+ опечаток word-level **практически перестаёт работать** (0.68 при 30%, 0.34 при 50%), тогда как char n-grams сохраняют работоспособность (0.94 и 0.70).

Ограничения эксперимента: (1) в коде для каждого символа случайно выбирается одна из трёх операций (замена, удаление, перестановка), поэтому вероятность искажения p — это вероятность применения операции, а не гарантированная доля испорченных символов; (2) замены выполняются символами латинского алфавита с диакритикой, что может неравномерно влиять на разные языки (особенно на русский, использующий кириллицу); (3) эксперимент

проведён с одним фиксированным seed, без доверительных интервалов и повторов с разными seed. Результаты следует трактовать как оценку устойчивости в рамках конкретного синтетического сценария искажения, а не как универсальный показатель.

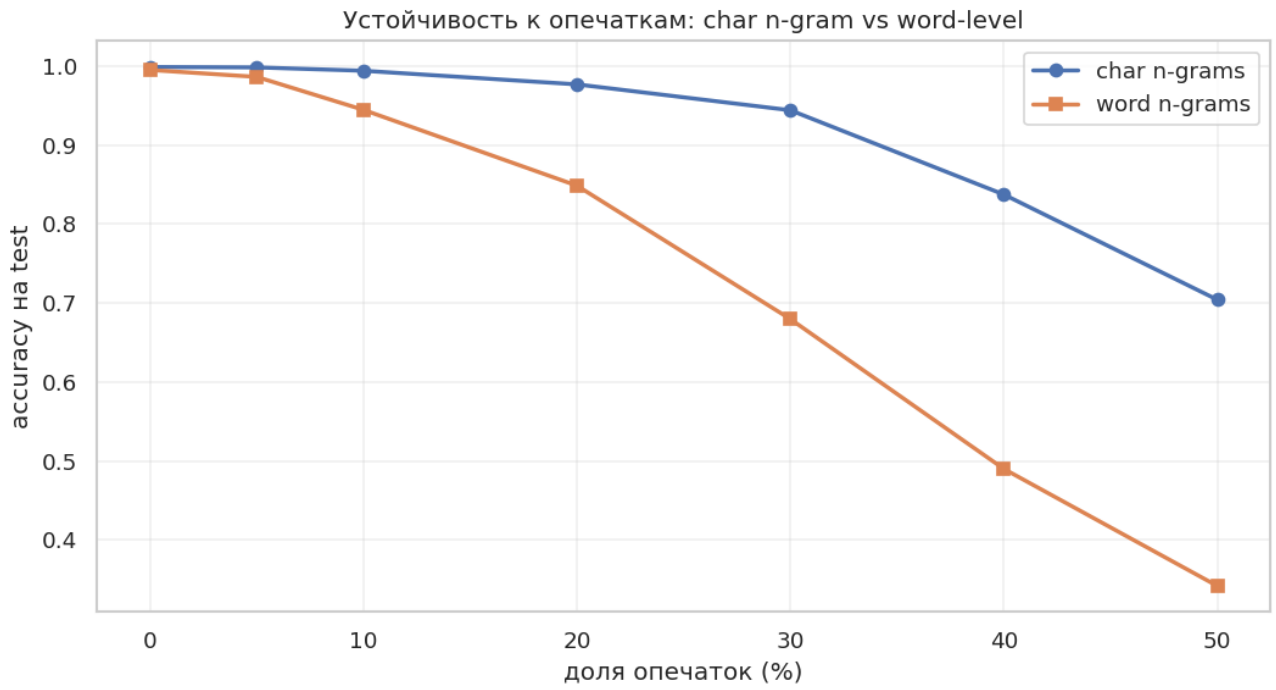


Figure 8: Accuracy vs доля опечаток.

7 Заключение

В работе построен и исследован классификатор языка короткого текста на основе символьных n-грамм. Основные результаты:

1. **Точность 0.999** (macro-F1 = 0.999) на полных текстах — 4 ошибки из 4 000.
2. **Сравнение моделей:** LinearSVC (0.9995) > LogReg (0.9985) > MNB (0.9975) на validation. На этом датасете все три модели применимы; SVC предпочтителен по F1, MNB — по простоте.
3. **Подбор n-грамм:** оптимум — `(1,4)` или `(2,4)` при `min_df=5`; униграммы не критичны.
4. **Интерпретируемость:** модель выделяет как лингвистические признаки (`'ão'`, `'ción'`, `'zione'`), так и орфографические и форматные.
5. **Роль алфавита:** при транслитерации `ru` → лат. точность падает с 1.000 до 0.000, что показывает зависимость модели от исходного алфавита.
6. **Устойчивость к длине:** на 5-символьных текстах char — 0.769, word — 0.638 (+13.1 п.п.).
7. **Устойчивость к опечаткам:** при 30% char — 0.944, word — 0.680 (+26.4 п.п.); при 50% — 0.704 vs 0.342.

Главный вывод: символьные n-граммы — правильный выбор для задачи определения языка короткого текста. На длинных текстах они эквивалентны word-level, но на коротких (≤ 20 символов) и при опечатках ($\geq 20\%$) дают прирост 10–36 п.п.

Ограничения. Близкородственные языки с общим алфавитом (es/it/pt) — основная зона ошибок; имена собственные и топонимы «ломают» n-граммы; смешанные языки объективно неоднозначны; тексты ≤ 3 символов не имеют решения без контекста. Дополнительно: 2.8% test-текстов встречаются в train (пересечение официального разбиения `papluca/language-identification`), что может давать завышение accuracy порядка 0.3 п.п.